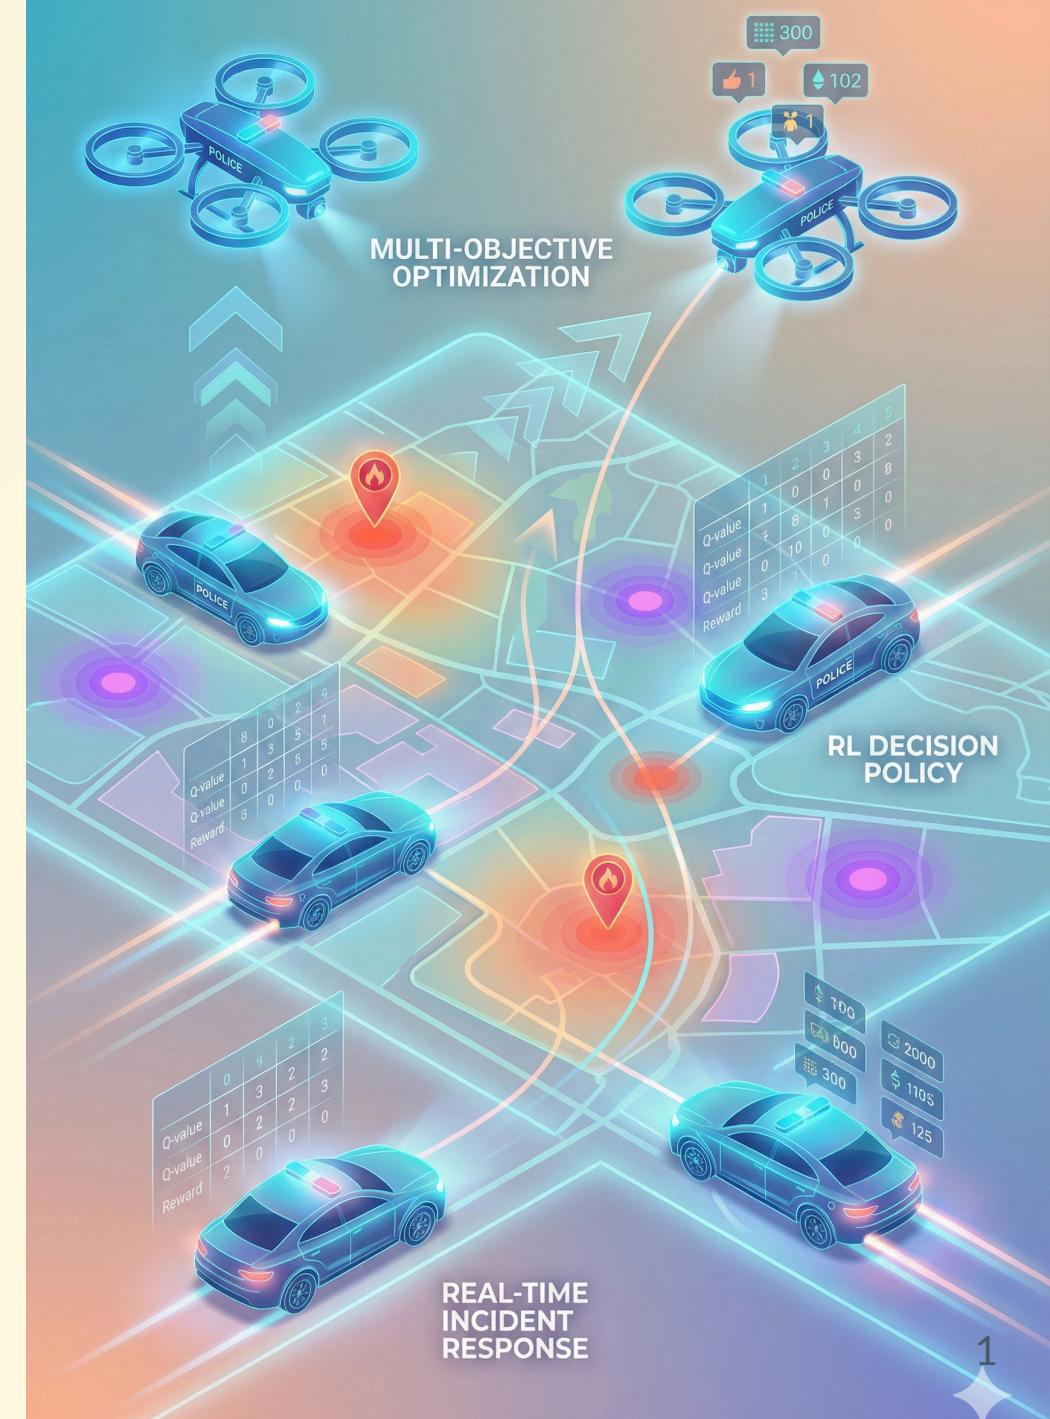


# **Abordagem Multiagente na combinação de ações de patrulhamento preventivo e de atendimento de chamadas policiais**

# Moacir Almeida Simões Júnior Tobias de Abreu Kuse



# O Problema e os Objetivos

## O Desafio Central

Equilibrar dois objetivos conflitantes da atividade policial:

1. **Patrulhamento Preventivo:** Maximizar a presença policial em áreas de alto risco (*hotspots*) para inibir crimes.
2. **Atendimento Reativo:** Minimizar o tempo de resposta a chamadas de emergência.

## A Solução Proposta

Um **sistema multiagente (MARL)** onde as patrulhas são agentes autônomos que aprendem uma **política de patrulhamento** para otimizar ambos os objetivos simultaneamente.

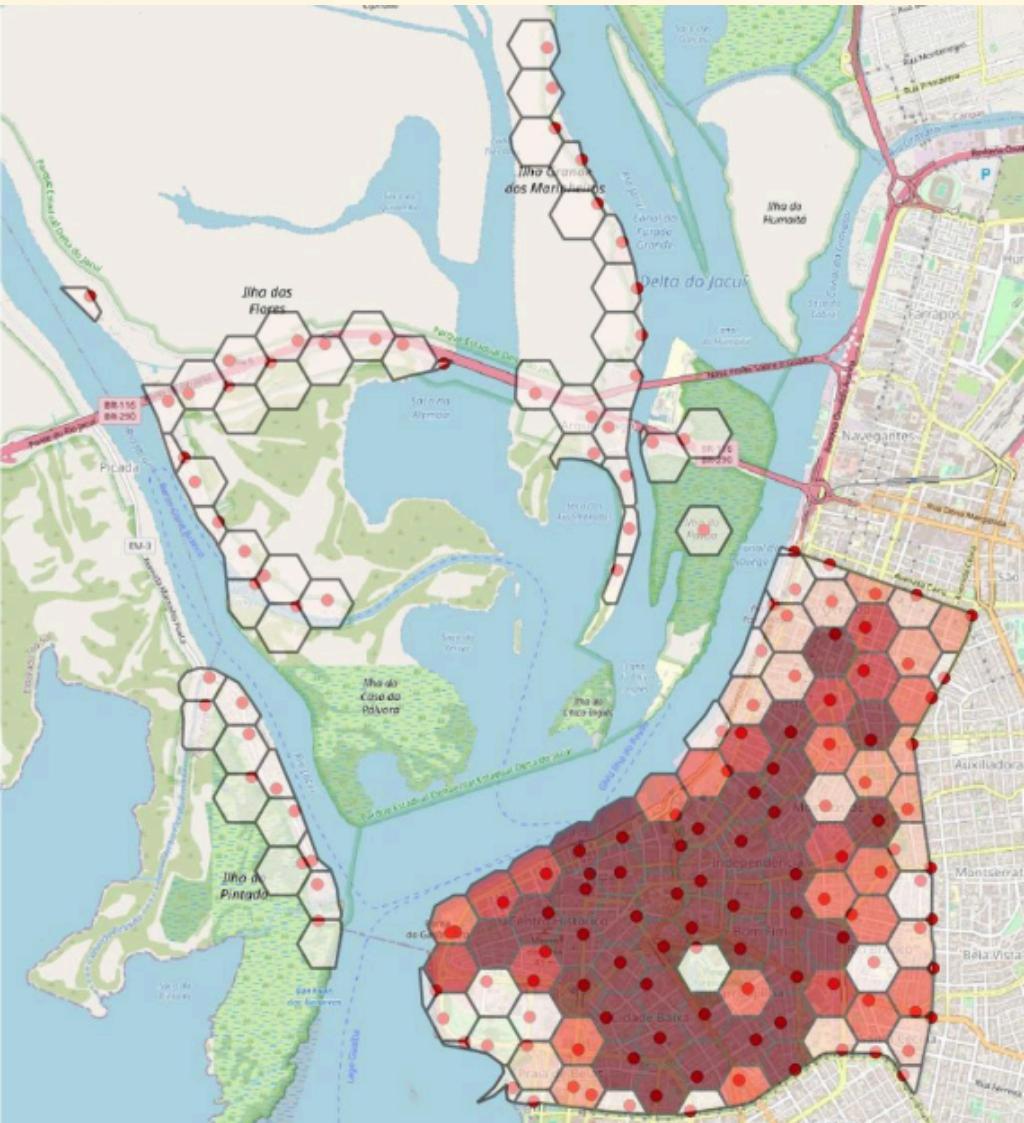
# Metodologia: Visão Geral

## Ambiente de Simulação

- Baseado em **dados reais** do 9º Batalhão de Polícia Militar (Porto Alegre/RS).
- Utiliza um **grid hexagonal** para representar o espaço geográfico.

## Identificação de Hotspots

- Um modelo preditivo (**XGBoost**), treinado com dados históricos, classifica os hexágonos com base no **risco de ocorrência** de eventos para as próximas 2 horas.



# Metodologia: Dinâmica da Simulação

## Simulação de Eventos Discretos

- Desenvolvida em Python (`simpy`), modela a operação minuto a minuto.
- **Entidade Patrulha:** Evolui por estados (Disponível, Deslocamento, Atendimento, etc.).
- **Lógica do Despachante:** Regras fixas (mais próximo para P1, da própria área para P2/P3).
- **O MARL atua** quando a patrulha está no estado `DISPONÍVEL`, decidindo para onde ir.
- **Eventos Aleatórios:** A chegada de chamadas é modelada por uma **distribuição de Poisson** (para os intervalos entre chamadas). O tempo de atendimento de cada ocorrência é sorteado de uma **distribuição exponencial**.

# Metodologia: Formulação MARL

O problema é formulado como um **Processo de Decisão de Markov (MDP) multiagente e cooperativo**, definido pela tupla:

$$\mathcal{M} = \langle \mathcal{A}, \mathcal{S}, \mathcal{U}, P, R, \gamma \rangle$$

- **Agentes ( $\mathcal{A}$ ):** As próprias patrulhas policiais.
- **Estado ( $\mathcal{S}$ ):** Uma representação do ambiente (posições, filas, etc.).
- **Ações ( $\mathcal{U}$ ):** O conjunto de vértices de patrulhamento que um agente pode escolher.
- **Transição ( $P$ ):** A dinâmica do simulador, que atualiza o estado a cada minuto.
- **Recompensa ( $R$ ):** Uma recompensa global compartilhada entre todos os agentes.
- **Fator de Desconto ( $\gamma$ ):** Parâmetro que pondera a importância de recompensas futuras.

# Formulação MARL: Agentes e Estados

## Agentes (A)

Os **agentes** no modelo são as próprias **patrulhas policiais**.

- Cada patrulha opera como um agente de decisão independente.
- O objetivo é aprender uma política que contribua para o bem comum do sistema.

## Estado (S) vs. Observação ( $o_i$ )

- **Estado Global ( $S$ ):** A "verdade absoluta" do simulador (todas as patrulhas, chamadas, etc.).
- **Observação Local ( $o_i$ ):** A visão **parcial** que cada agente  $i$  tem do mundo (o vetor de 19 dimensões), que é a entrada para sua rede neural.

# Formulação MARL: Ações e Transições

## Ações (U)

O **espaço de ações ( $\mathcal{U}$ )** define o que um agente pode fazer.

- É **discreto**: a ação ( $u_i$ ) é a escolha de um **vértice de destino** para patrulhamento (hotspots ou quartéis).

## Transição (P)

A **função de transição ( $P$ )** são as "regras da física" do ambiente.

- É a própria **dinâmica do simulador**: processa as ações, introduz eventos aleatórios (chamadas) e atualiza o estado do mundo a cada minuto.

# Formulação MARL: Recompensa (R)

A recompensa é **global e compartilhada** para incentivar a cooperação.

$$r_t = \alpha \cdot \Delta\text{atendidos}_t - \lambda_{\text{idle}} \cdot \widetilde{\Delta\text{idle}}_t - \lambda_{\text{resp}} \cdot \widetilde{\Delta\text{resp}}_t - \lambda_{\text{back}} \cdot \widetilde{\Delta\text{backlog}}_t$$

- **Componentes da Recompensa:**

- $\Delta\text{atendidos}_t$  (**Positivo**): Recompensa por chamados atendidos no minuto, ponderado pela prioridade. Incentiva a **eficiência**.
- $\widetilde{\Delta\text{idle}}_t$  (**Negativo**): Penaliza o aumento da ociosidade acumulada nos hotspots. Incentiva a **prevenção**.
- $\widetilde{\Delta\text{resp}}_t$  (**Negativo**): Penaliza o aumento do tempo de resposta acumulado (ponderado por prioridade). Incentiva a **agilidade**.
- $\widetilde{\Delta\text{backlog}}_t$  (**Negativo**): Penaliza o aumento de chamadas esperando na fila. Incentiva a **capacidade do sistema**.

\* Os termos com til ( $\widetilde{\cdot}$ ) representam versões normalizadas dos deltas.

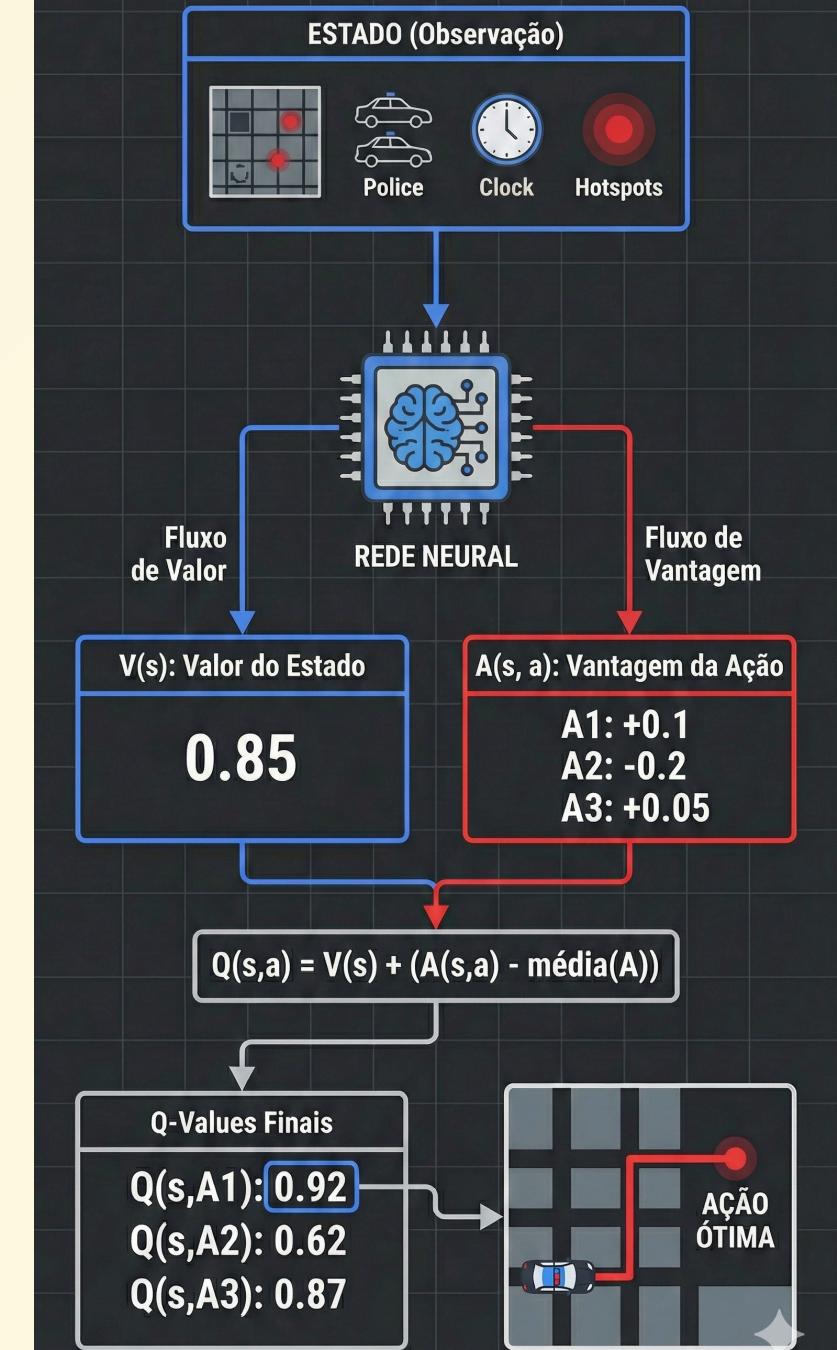
# Metodologia: Arquitetura da Rede (Dueling DQN)

A função de valor  $Q(o, u)$  de cada agente é aproximada por uma rede neural (MLP) com a arquitetura **Dueling DQN**.

Esta arquitetura possui dois "fluxos" separados:

- Fluxo do Valor:** Estima o quanto bom é o estado atual -  $V(s)$ .
- Fluxo da Vantagem:** Estima a vantagem de cada ação naquele estado -  $A(s, a)$ .

Os dois ramos são combinados para gerar os Q-values finais, o que estabiliza o aprendizado:  
$$Q(s, a) = V(s) + (A(s, a) - \text{mean}(A(s, a)))$$



# Validação: Setup Experimental

## Estratégias Comparadas

1. **MARL\_8**: A melhor configuração encontrada para o modelo MARL após vários experimentos.
2. **BAPS**: Uma heurística forte (baseada em Otimização por Colônia de Formigas) usada como baseline de alto desempenho.
3. **ALEATÓRIO**: Uma baseline simples onde as patrulhas escolhem destinos aleatoriamente.

## Condições de Avaliação

- Foram realizadas 3 execuções de simulação com horizonte de 7 dias.
- Para garantir uma comparação justa, **todas as estratégias foram avaliadas sob o mesmo conjunto de chamadas geradas**.

# Resultados: Comparação Geral

Método	Ociosidade	Fila	Deslocamento	Tempo Resposta
ALEATÓRIO	4843.14	39.52	<b>7.03</b>	46.54
BAPS	<b>4516.59</b>	<b>27.93</b>	7.10	<b>35.03</b>
MARL_8	4645.42	34.47	7.25	41.71

## Análise

- A heurística **BAPS** (guiada por risco) se confirmou como a mais eficiente no geral, alcançando os menores tempos de resposta, fila e ociosidade.
- O modelo **MARL\_8** superou significativamente a baseline **ALEATÓRIA** em todas as métricas.
- O resultado do **MARL** é promissor, pois se aproxima de uma heurística forte, validando que o agente aprendeu uma política coerente.

# Resultados: Análise por Prioridade de Fila

Prioridade	ALEATÓRIO	BAPS	MARL_8
Prioridade 1 (Crítica)	5.04	<b>0.00</b>	0.06
Prioridade 2 (Interm.)	49.82	25.73	<b>15.22</b>
Prioridade 3 (Baixa)	48.07	<b>28.82</b>	40.82

## Análise

- **P1:** BAPS e MARL\_8 são quase ótimos, zerando a fila para chamadas críticas.
- **P3:** BAPS é melhor. O MARL sacrifica o desempenho em baixa prioridade para otimizar as demais, um comportamento esperado e ajustável.
- **P2:** O MARL-8 foi **superior à heurística BAPS**, indicando que o agente aprendeu uma política de posicionamento mais eficaz para chamadas de prioridade intermediária.

# Resultados: O Achado Principal (Prioridade 2)

O modelo **MARL\_8** apresentou um desempenho **superior** ao da heurística BAPS para chamadas de prioridade intermediária.

- **Fila Média (Prioridade 2):**

- **MARL\_8:** 15.22 min
- **BAPS:** 25.73 min

## Hipótese

A abordagem **MARL** aprendeu uma política de patrulhamento mais sofisticada. Ela parece ter identificado um padrão de posicionamento que equilibra melhor a cobertura de zonas de alto risco com a necessidade de estar próximo a áreas de demanda moderada, algo que a heurística, com suas regras mais rígidas, não captura explicitamente.

# Conclusão

## Principais Conclusões

- A heurística **BAPS** se mostrou mais eficiente no agregado, mas o **MARL** é altamente competitivo.
- O **MARL** se destacou na prioridade 2, indicando que aprendeu políticas de posicionamento complexas e não óbvias.
- É possível obter ganhos operacionais relevantes **ajustando apenas o padrão de patrulhamento** (o que o MARL faz), sem alterar as regras de despacho.

## Contribuições

- Integração de patrulhamento preventivo e reativo em um único simulador.
- Formulação do problema como MDP multiagente com recompensa multiobjetivo.
- Validação empírica com dados reais de uma unidade policial brasileira.

# Trabalhos Futuros

- 1. Estender o MARL para o Despacho:** Modelar o despachante também como um agente de RL, permitindo o aprendizado de políticas de despacho dinâmicas, em vez de usar regras fixas.
- 2. Funções de Recompensa Adaptativas:** Investigar recompensas que se ajustem por prioridade, para calibrar de forma mais fina o trade-off entre os diferentes níveis de criticidade das chamadas.
- 3. Análise de Robustez e Transferibilidade:** Avaliar o desempenho do modelo em diferentes cenários de demanda (e.g., eventos especiais, crises) e testar a transferibilidade das políticas aprendidas para outras cidades ou contextos operacionais.

# Obrigado! 🙌

Perguntas?